



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

НА ТЕМУ:

**Методы классификации изображений и их сравнение
на гистопатологических данных**

Студент ИУ5-31М
(Группа)

Е.К. Сахарова
(Подпись, дата) (И.О.Фамилия)

Руководитель

Ю.Е. Гапанюк
(Подпись, дата) (И.О.Фамилия)

2024 г.

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

УТВЕРЖДАЮ
Заведующий кафедрой ИУ5
(Индекс)
В.И. Терехов
(И.О.Фамилия)
« 04 » сентября 2023 г.

ЗАДАНИЕ
на выполнение научно-исследовательской работы

по теме _____

Студент группы ИУ5-31М

Сахарова Елизавета Константиновна
(Фамилия, имя, отчество)

Направленность НИР (учебная, исследовательская, практическая, производственная, др.)

ИССЛЕДОВАТЕЛЬСКАЯ

Источник тематики (кафедра, предприятие, НИР) КАФЕДРА

График выполнения НИР: 25% к ____ нед., 50% к ____ нед., 75% к ____ нед., 100% к ____ нед.

Техническое задание Исследовать современные нейронные сети для распознавания изображений, применить их на наборе данных гистопатологических изображений для классификации заболеваний, проанализировать полученные результаты и выбрать наиболее надежную модель для выполнения данной задачи.

Оформление научно-исследовательской работы:

Расчетно-пояснительная записка на 15 листах формата А4.

Перечень графического (иллюстративного) материала (чертежи, плакаты, слайды и т.п.)

Дата выдачи задания « 04 » сентября 2024 г.

Руководитель НИР

Ю.Е. Гапанюк

(Подпись, дата)

(И.О.Фамилия)

Студент

Е.К. Сахарова

(Подпись, дата)

(И.О.Фамилия)

Примечание: Задание оформляется в двух экземплярах: один выдается студенту, второй хранится на кафедре.

Содержание

Введение.....	4
1 Смежные исследования	5
2 Методы классификации.....	5
3 Сравнение методов	8
Заключение	13
Список литературы	14

Введение

На протяжении многих лет микроскопические особенности тканей человека, известные как морфология, играли решающую роль в постановке диагноза. Такие морфологические характеристики, как форма клеток, их распределение и структура тканей, представляют собой важные индикаторы, позволяющие специалистам точно опознать различные заболевания.

Диагностика заболеваний включает в себя анализ и интерпретацию информации из различных источников [1]. Патологоанатомы играют решающую роль, проводя обследование пациентов и обобщая полученные результаты в патологоанатомическом заключении. Благодаря своим знаниям и опыту они создают целостное представление о пациенте, необходимое для определения его ситуации в рамках болезни и последующего лечения.

Этот процесс уменьшает неопределенность и разнообразие симптомов в клинической состоянии пациента, способствуя постановке более точного диагноза. Вопреки распространенному мнению, патологоанатом редко ставит окончательный диагноз самостоятельно, он скорее является частью общей диагностической цепочки. Как правило, окончательный диагноз представляет собой описательный текст с указанием основных клинических проявлений и патологоанатомических данных заболевания определенного человека, чтобы обеспечить понимание ситуации врачами разных специальностей.

Понимание диагностического процесса и роли патологоанатома имеет ключевое значение для развития искусственного интеллекта в патологии. Эти знания способствуют созданию эффективных и точных диагностических инструментов и интеграции технологий, что в конечном итоге повышает качество лечения.

1 Смежные исследования

Искусственный интеллект (ИИ) в последние годы занимает все более значительное место в области медицины, открывая новые горизонты для диагностики и лечения заболеваний. Его применение охватывает широкий спектр направлений, включая диагностику кожных заболеваний (96% и 94% распознавания карциномы и меланомы соответственно с помощью модели Inception v3), радиологию (классификация, сегментация, идентификация и локализация отдельных объектов), ультразвуковую диагностику (улучшение качества и эффективности обработки ультразвуковых изображений, методы ультразвуковой визуализации, сжатие и подавление помех) и патогистологию [2, 3, 4].

Одним из ключевых аспектов использования ИИ в медицине является его способность справляться с множеством сложных задач, требующих высокой степени точности и надежности. Например, в радиологии ИИ может анализировать снимки и выявлять патологии, которые могут быть не заметны человеческому глазу. В патогистологии алгоритмы могут помочь в классификации клеток и тканей, что значительно ускоряет процесс диагностики.

Однако с такими возможностями приходит и серьезная ответственность. Разработчикам необходимо создавать адаптивный код, который способен эффективно взаимодействовать с алгоритмами ИИ. Это требует глубокого понимания как медицинских аспектов, так и технологий машинного обучения.

2 Методы классификации

Сверточная нейронная сеть (CNN) – это тип искусственной нейронной сети, состоящей из входного, выходного и нескольких скрытых слоев [5, 6]. Три модели — VGG16, MobileNetV3 и DenseNet — представляют собой мощные инструменты для классификации гистопатологических изображений, каждая из которых имеет свои уникальные преимущества.

VGG16 — это модель сверточной нейронной сети, разработанная в качестве модели для соревнования [7]. Как следует из названия, архитектура данной модели состоит из 16 слоев, из которых 13 являются сверточным, 5 — с максимальным объединением, а 3 — плотными, что в сумме даёт 21 слой, но только 16 из которых являются весовыми.

Особенностью VGG16 является то, что вместо большого количества гиперпараметров, в модели используются слои свертки фильтра 3x3 с шагом 1 и всегда применяют одно и то же дополнение и слой максимального пула фильтра 2x2 с шагом 2.




Рис. 1. Архитектура VGG16

MobileNetV3 — это передовая архитектура нейронной сети, разработанная для использования в мобильных приложениях [8]. Она обеспечивает повышенную производительность и более эффективное использование вычислительных ресурсов по сравнению со своими предыдущими моделями. MobileNetV3 сочетает в себе методы оптимизации архитектуры, учитывающие аппаратные ограничения, и новые архитектурные решения. Благодаря своей адаптивности и производительности, она является идеальным выбором для проектов, в которых разработчики хотят внедрить решения для машинного обучения на мобильных устройствах, что особенно важно для медицинской области в условиях, где требуется оперативная диагностика.

По сравнению с другими архитектурами нейронных сетей, MobileNetV3 обеспечивает баланс между производительностью и экономичностью. Хотя

другие архитектуры могут обеспечивать более высокую точность, они часто отличаются повышенной вычислительной сложностью.




Рис. 2. Архитектура MobileNetV3

DenseNet, или Dense Convolutional Network – плотная сверточная сеть, представляет собой архитектуру глубокого обучения для сверточных нейронных сетей [9].

В отличие от традиционных архитектур сверточных сетей, где каждый слой подключен только к последующим слоям, в DenseNet каждый слой соединен с каждым другим слоем в прямом порядке, что позволяет значительно повысить точность прогнозирования без риска переобучения. Это делает DenseNet особенно полезной в задачах, связанных с анализом сложных гистопатологических изображений, где требуется высокая степень детализации и точности. DenseNet может быть интегрирована в гибридные модели, что дополнительно увеличивает их эффективность и надежность.




Рис. 3. Архитектура DenseNet

3 Сравнение методов

Для проведения экспериментов использовались три модели: VGG16, MobileNetV3 и DenseNet. Они были обучены на наборе данных, состоящим из 15000 микроскопических изображений разных типов злокачественных заболеваний крови [10]. Данные можно разделить на три категории по 5000 изображений: хронический лимфолейкоз – cl, фолликулярная лимфома – fl, мантийноклеточная лимфома – mcl (рис. 4).




Рис. 4. Примеры набора данных: а) хронический лимфолейкоз (cl), б) фолликулярная лимфома (fl), в) мантийноклеточная лимфома (mcl)

Основываясь на результатах экспериментов, проведенных после обучения и тестирования модели на обучающих (80% от исходного набора) и тестовых (20% от исходного набора) данных, модель DenseNet демонстрирует более высокую точность в распознавании классов набора данных по сравнению с другими алгоритмами (рис. 5 – 10).

Training Set				
TARGET OUTPUT	cil	fl	mcl	SUM
cil	831 27.70%	52 1.73%	117 3.90%	1000 83.10% 16.90%
fl	35 1.17%	811 27.03%	154 5.13%	1000 81.10% 18.90%
mcl	40 1.33%	42 1.40%	918 30.60%	1000 91.80% 8.20%
SUM	906 91.72% 8.28%	905 89.61% 10.39%	1189 77.21% 22.79%	2560 / 3000 85.33% 14.67%

Рис. 5. Матрица ошибок VGG16

Training Set				
TARGET OUTPUT	cil	fl	mcl	SUM
cil	899 29.97%	19 0.63%	82 2.73%	1000 89.90% 10.10%
fl	53 1.77%	881 29.37%	66 2.20%	1000 88.10% 11.90%
mcl	120 4.00%	83 2.77%	797 26.57%	1000 79.70% 20.30%
SUM	1072 83.86% 16.14%	983 89.62% 10.38%	945 84.34% 15.66%	2577 / 3000 85.90% 14.10%

Рис. 6. Матрица ошибок MobileNetV3

Training Set				
TARGET \ OUTPUT	cil	fl	mcl	SUM
cil	904 30.13%	5 0.17%	91 3.03%	1000 90.40% 9.60%
fl	8 0.27%	797 26.57%	195 6.50%	1000 79.70% 20.30%
mcl	1 0.03%	4 0.13%	995 33.17%	1000 99.50% 0.50%
SUM	913 99.01% 0.99%	806 98.88% 1.12%	1281 77.67% 22.33%	2696 / 3000 89.87% 10.13%

Рис. 7. Матрица ошибок DenseNet

Class Name	Precision	1-Precision	Recall	1-Recall	f1-score
cil	0.8310	0.1690	0.9172	0.0828	0.8720
fl	0.8110	0.1890	0.8961	0.1039	0.8514
mcl	0.9180	0.0820	0.7721	0.2279	0.8387
Accuracy	0.8533				
Misclassification Rate	0.1467				
Macro-F1	0.8541				
Weighted-F1	0.8526				

Рис. 8. Статистические метрики VGG16

Class Name	Precision	1-Precision	Recall	1-Recall	f1-score
cil	0.8990	0.1010	0.8386	0.1614	0.8678
fl	0.8810	0.1190	0.8962	0.1038	0.8886
mcl	0.7970	0.2030	0.8434	0.1566	0.8195
Accuracy	0.8590				
Misclassification Rate	0.1410				
Macro-F1	0.8586				
Weighted-F1	0.8594				

Рис. 8. Статистические метрики MobileNetV3

Class Name	Precision	1-Precision	Recall	1-Recall	f1-score
cil	0.9040	0.0960	0.9901	0.0099	0.9451
fl	0.7970	0.2030	0.9888	0.0112	0.8826
mcl	0.9950	0.0050	0.7767	0.2233	0.8724
Accuracy	0.8987				
Misclassification Rate	0.1013				
Macro-F1	0.9001				
Weighted-F1	0.8973				

Рис. 8. Статистические метрики DenseNet

В медицинской диагностике следует избегать ложноотрицательных (FN – False Negative) результатов, поскольку в жизни они могут иметь летальные последствия. В таком случае recall является оптимальным выбором при оценке алгоритмов, чем precision. В полученных результатах, которые приведены в таблице, можно прийти к выводу, что DenseNet показывает наилучшие результаты.

Точность алгоритмов

Методы	Accuracy	Recall			Precision		
		cII	fI	mcl	cII	fI	mcl
VGG16	85,33%	91,72%	89,61%	77,21%	83,1%	81,1%	91,8%
MobileNetV3	85,9%	83,86%	89,62%	84,34%	89,9%	88,1%	79,7%
DenseNet	89,87%	99%	98%	77,67%	90,4%	79,7%	99,5%

Заключение

В данной работе были использованы три метода глубокого обучения для изучения классификации гистопатологических изображений в медицинской практике. Согласно полученным результатам, DenseNet классифицирует заболевания лучше по сравнению с остальными моделями, учитывая такую важную метрику как recall. В результате, внедрение ИИ в медицинскую практику открывает новые возможности для диагностики различных патологий. Это может привести к более раннему выявлению заболеваний, другому мнению по постановке диагноза, если врачи разошлись в выводах, улучшению качества лечения и, в конечном итоге, повышению уровня здоровья населения. Однако нужно стремиться повышать точность прогноза, так как, проектируя модели для распознавания злокачественных патологий важно помнить, что неправильно поставленный диагноз приведет к изначально неправильному лечению, в следствие чего приведет к летальному исходу.

Список литературы

1. Pena G. P., Andrade-Filho J. S. How does a pathologist make a diagnosis? //Archives of pathology & laboratory medicine. – 2009. – Т. 133. – №. 1. – С. 124-132.
2. Cheng P. M. et al. Deep learning: an update for radiologists //Radiographics. – 2021. – Т. 41. – №. 5. – С. 1427-1445.
3. Esteva A. et al. Dermatologist-level classification of skin cancer with deep neural networks //nature. – 2017. – Т. 542. – №. 7639. – С. 115-118.
4. Van Sloun R. J. G., Cohen R., Eldar Y. C. Deep learning in ultrasound imaging //Proceedings of the IEEE. – 2019. – Т. 108. – №. 1. – С. 11-29.
5. A. Kanev, M. Nazarov, D. Uskov and V. Terentyev, "Research of Different Neural Network Architectures for Audio and Video Denoising," 2023 5th International Youth Conference on Radio Electronics, Electrical and Power Engineering (REEPE), Moscow, Russian Federation, 2023, pp. 1-5, doi: 10.1109/REEPE57272.2023.10086862.
6. Канев А.И. Сравнение производительности моделей глубокого обучения при запуске на клиентском устройстве и в облаке. Нейрокомпьютеры: разработка, применение. 2023. Т. 25. № 6. С. 27-36.
7. Simonyan K., Zisserman A. Very deep convolutional networks for large-scale image recognition //arXiv preprint arXiv:1409.1556. – 2014.
8. Howard A. et al. Searching for mobilenetv3 //Proceedings of the IEEE/CVF international conference on computer vision. – 2019. – С. 1314-1324.

9. Huang G. et al. Densely connected convolutional networks //Proceedings of the IEEE conference on computer vision and pattern recognition. – 2017. – C. 4700-4708.
10. Orlov N. V. et al. Automatic classification of lymphoma images with transform-based global features //IEEE Transactions on Information Technology in Biomedicine. – 2010. – T. 14. – №. 4. – C. 1003-1013.